

Trabajo Evaluativo 1: Informe

Analizando el siguiente dataset se definirán el tipo de variables:

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	student_id	name	gender	age	grade_level	math_score	reading_score	writing_score	attendance_rate	parent_education	study_hours	internet_access	lunch_type	extra_activities	final_result
2	S1	Student_1	Other	17	10	74	61	90	94.66000214	Master's	4.120192348	Yes	Free or reduce	Yes	Fail
3	S2	Student_2	Male	17	12	99	70	91	93.1732271	Bachelor's	2.886505461	No	Free or reduce	No	Pass
4	S3	Student_3	Other	17	9	59	60	99	98.63109829	PhD	1.909926415	No	Free or reduce	No	Fail
5	S4	Student_4	Other	17	12	70	88	69	96.41962035	PhD	1.664739998	No	Standard	No	Pass
6	S5	Student_5	Male	15	9	85	77	94	91.33210518	PhD	2.330917906	Yes	Free or reduce	No	Pass
7	S6	Student_6	Male	17	11	61	54	89	93.14060996	Master's	4.759697492	No	Free or reduce	Yes	Fail
8	S7	Student_7	Other	16	9	76	66	88	97.96772933	Bachelor's	2.37210685	Yes	Free or reduce	No	Pass
9	S8	Student_8	Female	16	11	89	69	98	87.99037569	PhD	4.952496304	No	Standard	Yes	Pass
10	S9	Student_9	Other	17	12	51	90	72	86.53589412	High School	2.940921823	No	Standard	No	Pass
11	S10	Student_10	Other	17	11	62	95	96	80.21622167	Bachelor's	1.716655673	Yes	Standard	Yes	Fail
12	S11	Student_11	Other	16	12	81	61	81	96.53102148	High School	4.564560367	Yes	Free or reduce	Yes	Pass
13	S12	Student_12	Other	16	10	80	55	96	96.01961401	High School	2.841421493	No	Free or reduce	Yes	Pass
14	S13	Student_13	Male	15	10	65	66	82	82.08909036	PhD	3.838685374	No	Free or reduce	Yes	Pass
15	S14	Student_14	Other	16	10	81	68	95	91.53714762	PhD	4.934846333	Yes	Standard	Yes	Fail
16	S15	Student_15	Female	16	11	81	75	54	89.27963396	Master's	1.200701401	No	Free or reduce	No	Fail
17	S16	Student_16	Male	17	10	83	97	92	82.37418191	Master's	1.386778239	Yes	Standard	Yes	Fail
18	S17	Student_17	Female	16	9	60	93	97	99.61136454	Master's	3.881826966	Yes	Standard	No	Fail

Variables Cuantitativas Discretas

Son variables que tipo numérico las cuales pueden tomar valores enteros que pueden ser contados:

- Age (edad de los estudiantes)
- Grade_level (grado escolar)
- Math_score (nota de matemática)
- Reading_score (nota en lectura)
- Writting_score (nota de escritura)

Variables Cuantitativas Continuas

Variables de tipo numérico las cuales pueden tomar cual valor medible y que este en el rango de los decimales

- Attedance_rate (porcentaje de asistencia)
- Study_hours (horas de estudio)

Variables Cualitativas Nominales

- Student_id (id de alumno)
- Name
- Gender
- Internet_access
- Lunch_type
- Extra_activities
- Final_result

Variables Cualitativas Ordinales

- Parent_education (nivel de estudios de los padres)

Medias de Tendencia Central

Indica hacia donde se agrupa o concentran los datos

- **Media:** Es la suma de todos los valores entre su total de la muestra
- **Mediana:** Es el valor justo en la mitad de los datos ordenados de mayor a menor
- **Moda:** Es el valor que se repite con mayor frecuencia

```
df <- read_excel("student_info.xlsx")
num_cols <- c("math_score", "reading_score", "writing_score", "attendance_rate",
"study_hours")

get_mode <- function(v) unique(v)[which.max(tabulate(match(v, unique(v))))]
descriptiva <- data.frame(
  Media = sapply(df[num_cols], mean), Mediana = sapply(df[num_cols], median),
  Moda = sapply(df[num_cols], get_mode),
  Rango = sapply(df[num_cols], \ (x) max(x) - min(x)), Varianza =
sapply(df[num_cols], var),
  Desv_Est = sapply(df[num_cols], sd), IQR = sapply(df[num_cols], IQR)
)
print(round(descriptiva, 2))
```

	Media	Mediana	Moda	Rango	Varianza	Desv_Est	IQR
math_score	75.17	75.00	70.00	49.00	204.61	14.30	25.00
reading_score	74.29	74.00	66.00	49.00	204.85	14.31	24.00
writing_score	75.15	75.00	89.00	49.00	207.22	14.40	25.00
attendance_rate	89.88	89.98	94.66	19.95	32.78	5.73	9.66
study_hours	2.98	2.96	4.12	3.98	1.36	1.17	2.04

Medidas de Dispersión

Miden que tan dispersos están los datos respecto al centro

- **Rango:** Es la diferencia entre el valor máximo y valor mínimo
- **Varianza:** Mide la dispersión promedio al cuadrado respecto a la media
- **Desviación Estándar:** Es la raíz cuadrada de la varianza, muestra cuando se alejan en promedio los datos respecto a la media en las mismas unidades
- **Rango Intercuartílico:** Es la distancia entre el tercer cuartil y el primer cuartil

```
posicion <- t(sapply(df[num_cols], quantile, probs = c(0.10, 0.25, 0.50, 0.75,
0.90, 0.95)))
colnames(posicion) <- c("D1/P10", "Q1/P25", "Q2/P50", "Q3/P75", "D9/P90", "P95")
print(round(posicion, 2))
```

	D1/P10	Q1/P25	Q2/P50	Q3/P75	D9/P90	P95
math_score	55.00	63.00	75.00	88.00	95.00	97.00
reading_score	55.00	62.00	74.00	86.00	94.00	97.00
writing_score	55.00	63.00	75.00	88.00	95.00	97.00
attendance_rate	81.93	84.97	89.98	94.63	97.80	98.92
study_hours	1.41	1.96	2.96	3.99	4.64	4.84

Medidas de Forma

Mide el grado de simetría de los datos respecto a la media. Indica si la curva se inclina hacia algún lado o si está balanceada.

- **Asimetría = 0 (Simétrica):** La distribución es uniforme a ambos lados del centro; la media, la mediana y la moda coinciden. (Ej. Las notas de matemáticas tienen una asimetría de -0.05, lo que significa que están perfectamente centradas en 75).
- **Asimetría > 0 (Positiva Sesgada a la derecha):** La mayoría de los datos son bajos, pero hay una cola de valores altos a la derecha que estira el promedio.
- **Asimetría < 0 (Negativa Sesgada a la izquierda):** La mayoría de los datos son altos, pero hay valores bajos a la izquierda que arrastran la media hacia abajo.
- **Curtosis:** Mide que tan apuntada o aplanada es la distribución de los datos en comparación con una distribución normal.


```
forma <- data.frame(  
  Asimetria = sapply(df[num_cols], skewness),  
  Curtosis = sapply(df[num_cols], kurtosis)  
)  
print(round(forma, 2))
```

	Asimetría	Curtosis
math_score	-0.05	-1.18
reading_score	0.03	-1.17
writing_score	-0.02	-1.19
attendance_rate	0.02	-1.17
study_hours	0.05	-1.23

Medidas de la Forma

Las medidas de forma analizan cómo se distribuyen los datos respecto a su centro mediante la **asimetría** (sesgo) y la **curtosis** (apuntamiento)

```
g1 <- ggplot(df, aes(x = math_score)) +  
  geom_histogram(bins = 15, fill = "skyblue", color = "black") +  
  labs(title = "Distribución Matemáticas")  
  
g2 <- ggplot(df, aes(x = "Notas", y = math_score)) +  
  geom_boxplot(fill = "lightgreen") +  
  labs(title = "Boxplot Matemáticas (Cuartiles)")  
  
g3 <- ggplot(df, aes(x = final_result, y = attendance_rate, fill = final_result)) +  
  geom_boxplot() +  
  labs(title = "Asistencia por Resultado")  
  
g4 <- ggplot(df, aes(x = study_hours, y = math_score)) +  
  geom_point(color = "steelblue") +  
  labs(title = "Estudio vs Matemáticas")  
grid.arrange(g1, g2, g3, g4, ncol = 2)
```



Afirmación sobre la Población e Hipótesis H_0 y H_1

En estadística inferencial se busca verificar una idea o afirmación sobre la población a partir de una muestra. Para evaluarla se plantean dos hipótesis opuestas:

Hipótesis Nula (H_0): Representa la condición de "no efecto", "no diferencia" o "igualdad". Asume que cualquier diferencia observada se debe al azar.

Hipótesis Alternativa (H_1 o H_a): Es la afirmación del investigador; sostiene que existe un efecto real, una diferencia significativa o una relación.

Calcular del p-valor y su interpretación

El p-valor es la probabilidad de obtener un resultado tan o más extremo que el observado, asumiendo que la hipótesis nula (H_0) es verdadera. Se compara contra el nivel de significancia (habitualmente = 0.05 o 5%).

Si p-valor $\leq$ 0.05: Se rechaza H_0 . Hay evidencia estadística suficiente para concluir que el efecto o la diferencia es real.

Si p-valor $>$ 0.05: No se rechaza H_0 . No existe suficiente evidencia para afirmar que hay una diferencia significativa.

Evaluación para aplicar la Prueba t de Student

La prueba t de Student sirve para comparar la media de una variable cuantitativa continua entre 2 grupos independientes.

- La variable dependiente debe ser numérica continua como el math_score
- La variable independiente debe tener exactamente 2 categorías como el genero
- Distribución aproximadamente normal en los datos y muestra independiente.
- Aplicabilidad en el dataset: Sí es aplicable. Permite evaluar si la nota media de matemáticas difiere significativamente entre hombres y mujeres.

Evaluación para aplicar ANOVA (Análisis de Varianza)

La prueba ANOVA permite comparar las medias de una variable cuantitativa continua entre 3 o más grupos independientes al mismo tiempo.

- Variable dependiente numérica como el math_score
- Variable independiente cualitativa con 3 o más categorías como pueden ser parent_education
- Homogeneidad de varianzas (homocedasticidad) y normalidad.
- Aplicabilidad en el dataset: Sí es aplicable. Permite analizar si el nivel de educación de los padres influye en la nota promedio de matemáticas de los estudiantes.

Evaluación para aplicar Chi-cuadrado

La prueba de Chi-cuadrado de independencia se utiliza para determinar si existe una asociación o relación significativa entre dos variables cualitativas (categóricas).

Ambas variables deben ser cualitativas/categóricas (nominales u ordinales). Las observaciones deben organizarse en una tabla de contingencia (frecuencias). Las frecuencias esperadas por celda deben ser generalmente mayores a 5